

Енергетично-структурний метод класифікації без backpropagation для few-shot сценаріїв

Mykyta Lapin

Kostyantyn Bokhan

26 вересня 2025 р.

Мета, Актуальність та Висновки

Назва статті

Енергетично-структурний метод класифікації без backpropagation для few-shot сценаріїв.

(An Energy-Structural Classification Method without Backpropagation for Few-Shot Scenarios)

Мета статті

Розробити та обґрунтувати **ЕСМ-архітектуру** (Енергетична Структурна Модель), здатну до автономного формування стійких структурних концептів з візуальних даних для задачі few-shot класифікації без використання механізму зворотного поширення помилки. Мета полягає в демонстрації того, що ітеративна структурно-параметрична редукція, натхненна принципами мінімізації енергії, є ефективною альтернативою для навчання моделей, стійких до варіацій вхідних даних.

Актуальність

Сучасні глибокі нейронні мережі (ШНМ) демонструють високу ефективність, але мають суттєві обмеження: вони вимагають величезних обсягів даних, значних обчислювальних ресурсів для тренування через backpropagation, є вразливими до змалювальних атак і функціонують як "чорні скриньки". Актуальність цього дослідження полягає у пошуку альтернативної парадигми навчання, яка б забезпечувала прозорість, обчислювальну ефективність та здатність до навчання на малих вибірках (few-shot learning). Підхід, реалізований в ЕСМ, що імітує процеси самоорганізації та еволюції енергетичних систем, пропонує новий шлях до створення більш природного та стійкого штучного інтелекту.

Основні висновки

1. Розроблена ЕСМ-архітектура успішно реалізує беззворотний цикл навчання, заснований на ітеративному формуванні концепту-атрактора шляхом структурної та параметричної редукції.

2. Експерименти на датасеті MNIST демонструють, що підхід досягає конкурентоспроможної точності (до 82.4% з аугментацією)
3. Механізм редукції, керований енергетичними принципами, забезпечує формування прозорих та інтерпретованих концептів, що є ключовою перевагою над традиційними ШНМ.
4. Система демонструє високу стійкість до структурних "шумів" та варіацій, ефективно зводячи різноманітні вхідні зразки до єдиного канонічного представлення класу.

Розгорнутий план статті

Анотація (0.5 стор.)

- **Вступ:** Постановка проблеми обмеженості класичних ШНМ (залежність від backpropagation, великих даних, непрозорість).
- **Мета:** Представити ЕСМ — нову енерго-орієнтовану архітектуру для few-shot структурної класифікації.
- **Методологія:** Описати ключові етапи: скелетизація зображення для отримання графового представлення, ітеративна структурно-параметрична редукція для формування концепту-атрактора на основі енергетичних принципів.
- **Результати:** Навести ключові показники точності на датасеті MNIST (до 82.4%). Підкреслити, що точність зростає зі збільшенням кількості навчальних прикладів.
- **Висновки:** Акцентувати увагу на тому, що запропонований підхід є життєздатною альтернативою, яка забезпечує прозорість, стійкість класифікації та здатність до навчання на малих вибірках.

Ключові слова (до 8 термінів)

- Structural pattern recognition, concept formation, skeletonization, graph reduction, non-backpropagation learning, energy-based models, iterative learning, attractor dynamics.

1 Вступ (1 стор.)

- **Мотивація:** Критичний аналіз сучасних ШНМ. Проблеми "крихкості обчислювальної вартості, потреби у великих даних.
- **Наукова новизна:** Представити ідею навчання як процес самоорганізації та еволюції, що веде до мінімізації "внутрішньої енергії" системи. Замість градієнтного спуску по поверхні помилки — градієнтний спуск по енергетичному ландшафту структури.
- **Формулювання завдань:**
 1. Розробити пайплайн перетворення растрового зображення у стабільний граф.
 2. Сформулювати правила структурної та параметричної редукції.
 3. Реалізувати ітеративний механізм формування концепту.
 4. Розробити класифікаційний модуль на основі зіставлення графів.
 5. Експериментально перевірити гіпотезу на стандартному датасеті.
- **Очікувані результати:** Створення системи, що демонструє здатність до узагальнення, прозорість рішень та ефективного навчання на обмежених даних.

2 Огляд предметної області та існуючих рішень (1 стор.)

- **Структурна класифікація образів:** Короткий огляд класичних підходів (синтаксичний аналіз, зіставлення графів). Їх переваги (інтерпретованість) та недоліки (складність, чутливість до шуму).
- **Skeleton-based методи:** Аналіз конвеєрів, що використовують скелетизацію для розпізнавання символів, біометричних даних тощо.
- **Альтернативи без backpropagation:** Згадати про машини екстремального навчання (ELM), рідкі кодуючі мережі, модель Хопфілда та інші підходи, що уникають ітеративного градієнтного спуску.
- **Позиціонування ЕСМ:** Чітко визначити місце розробки. Акцент на поєднанні структурного підходу з енергетичними принципами самоорганізації, що відрізняє його від існуючих рішень.

3 Архітектура ЕСМ (2 стор.)

- **Загальний пайплайн:** Детальний опис схеми з *docs/images/basic_architecture.png*. Пояснити рух даних від вхідного зображення до фінального рішення.
- **Підрозділ 3.1: Попередня обробка:** Скелетизація та первинний аналіз контуру. Мета — отримати інваріантне до товщини ліній графове представлення.
- **Підрозділ 3.2: Формування концепту:** Вторинний аналіз, редукції, ітеративна композиція. Мета — знайти стабільний атрактор, що є узагальненим представленням класу.
- **Підрозділ 3.3: Класифікація та прийняття рішення:** Інференс як процес редукції вхідного образу до атрактора. Розрахунок активації, конкуренція концептів (WTA).
- **Таблиця/схема потоків даних:** Створити таблицю, що показує, які дані генеруються на кожному етапі (піксельна маска → скелет → первинний граф → редукований граф → концепт/рішення) та які ключові операції виконуються.

4 Практична реалізація компонентів (2 стор.)

- **4.1 Скелетизація та побудова графа:**
 - Алгоритми: Детально описати використаний алгоритм морфологічної скелетизації (напр., Zhang-Suen) та адаптивний вибір порогу. Згадати про Growing Neural Gas (GNG) для навчання топології та Ramer-Douglas-Peucker (RDP) для спрощення (з *README.md*).
 - Структура даних: Описати представлення графа (напр., за допомогою NetworkX), атрибути вузлів (тип точки, координати) та ребер (довжина, кут).

- Обчислювальна складність: Аналіз складності етапу, залежність від розміру зображення.
- **4.2 Первинний аналіз контуру:**
 - Параметри: Перелічити всі параметри, що обчислюються (кути, довжини, квадранти, напрямки). Пояснити важливість абсолютної та відносної систем координат (з *README.md*).
 - Нормалізація: Описати процес нормалізації координат для інваріантності до масштабу та зсуву.
- **4.3 Вторинний аналіз та редукції:**
 - Правила: Детально описати правила редукції ($\text{IntersectionPoint} \rightarrow \text{CornerPoint} \rightarrow \text{EndPoint}$, видалення кінцевих точок). Навести візуальні приклади, як у *README.md*.
 - Псевдокод: Навести псевдокод для ключових процедур, наприклад, для алгоритму знаходження шляху для видалення кінцевої точки.
- **4.4 Ітеративна композиція концептів:**
 - Завершення навчання: У поточній реалізації процес навчання для кожного концепту завершується після обробки всіх доступних тренувальних зразків. Критерії динамічної стабілізації не застосовуються.
 - Збереження атрактора: Описати механізм оновлення параметрів концепту (напр., перехід від абсолютних значень до діапазонів).

5 Механізм навчання та формування бази концептів (1 стор.)

- **Сценарій навчального циклу:** Покроковий опис:
 1. Береться перший зразок класу як початковий концепт.
 2. Береться наступний зразок, його граф редукується до структури поточного концепту.
 3. Виконується структурне та параметричне узагальнення (редукція) концепту на основі нового зразка.
 4. Процес повторюється для всіх навчальних зразків.
- **Організація даних:** Як зберігаються концепти (напр., у базі даних графів Neo4j, як згадується в коді, або у файловій системі). Структура збереженого концепту.
- **Керування стартовими точками:** Детально описати стратегію вибору стартової точки на основі кластеризації критичних точок (з *README.md*). Пояснити, чому стабільна стартова точка є критично важливою для консистентного аналізу.

6 Класифікаційний модуль (1 стор.)

- **Процедура інференсу:** Детальний опис кроків, що відбуваються під час класифікації нового зображення.
 1. Скелетизація та побудова графа.
 2. Для кожного концепту з бази:
 - Рання відмова (фільтр складності).
 - Редукція графа зображення до структури концепту.
 - Обчислення метрики активації.
 3. Вибір класу за принципом "переможець забирає все"(WTA).
- **Метрика активації:** Детально описати, як розраховується подібність. Використати ідею Graph Edit Distance (GED) як "енергії активації"(з *README.md*). Формула: $Similarity = 1 - (GED/MaxPossibleCost)$.
- **Логіка вибору класу:** Описати механізм WTA та правило вирішення нічий (tie-breaking) за допомогою складності концепту.

7 Експериментальні результати (1 стор.)

- **Налаштування експерименту:** Описати датасет (MNIST), кількість класів, кількість тренувальних зразків для кожного сценарію (без аугментації, +2, +5, +10).
- **Детальні таблиці:** Представити таблиці з *README.md* з метриками (Accuracy, Precision, Recall, F1-score) для кожного сценарію.
- **Аналіз трендів:** Проаналізувати, як змінюються метрики зі збільшенням навчальних даних. Підкреслити позитивну динаміку.
- **Графік:** Вставити та прокоментувати графік з *docs/images/augmentation_impact_chart.png*, що візуалізує вплив аугментації.
- **Обговорення:** Пояснити, чому аугментація настільки важлива для даного підходу (допомагає сформувати більш стійкий та узагальнений атрактор).

8 Обговорення та обмеження (0.5 стор.)

- **Сильні сторони:**
 - **Прозорість:** Можливість візуалізувати та аналізувати сформовані концепти.
 - **Беззворотне навчання:** Обчислювальна ефективність тренування.
 - **Навчання на малих даних:** Здатність формувати концепти з кількох прикладів.

- **Сценарії застосування:** Де цей підхід може бути корисним? (медична діагностика, розпізнавання рукописних символів — скрізь, де важлива структура та інтерпретованість).
- **Обмеження:**
 - **Масштабування:** Як система буде працювати з сотнями чи тисячами класів?
 - **Якість скелетизації:** Висока залежність результатів від першого етапу. Помилки на етапі скелетизації не можуть бути виправлені пізніше.
 - **Складні текстури:** Підхід погано працюватиме для зображень, де клас визначається текстурою, а не структурою (напр., класифікація порід тварин за хутром).
- **Порівняння з традиційними НМ:** Стисло підсумувати, в чому ЕСМ виграє, а в чому програє порівняно з CNN.

9 Висновки та подальша робота (0.5 стор.)

- **Підсумок:** Коротко резюмувати досягнуті результати — створено та валідовано архітектуру для беззворотного структурного навчання.
- **Досягнутий рівень автономності:** Система автономно формує концепти, але вибір стартових точок та правила редукції ще потребують ручного налаштування.
- **Дорожня карта:**
 - Розширення на більшу кількість класів та складніші датасети (напр., EMNIST, Quick, Draw!).
 - Оптимізація обчислювальної складності редукцій та зіставлення графів.
 - Автоматизація вибору гіперпараметрів (напр., порогів для кластеризації стартових точок).
 - Розробка "карт-нейронів" для моделювання варіативності всередині класів. Наприклад, узагальнюючий концепт "цифра 7" може об'єднувати під-концепти (атрактори) для різних стилів написання (з перетинкою та без).

10 Список літератури (0.8 стор.)

- Зібрати ключові статті по skeletonization (Zhang-Suen), structural pattern recognition (K. S. Fu), conceptual learning, non-backpropagation methods (Hopfield, ELM).
- Форматувати відповідно до вимог конкретного журналу.

11 Додатки (до 1 стор.)

- Навести більш детальні схеми правил редукції.
- Показати 2-3 приклади графів для цифр MNIST до та після повної редукції до концепту.
- Навести короткі, але ключові фрагменти псевдокоду для найбільш складних алгоритмів (напр., ітеративне оновлення концепту).